

Review Komprehensif Jurnal: Intelligent Recognition of Visual Speech Based on Custom CNN and Optimized Quaternion Charlier Moments Using PSO

Reviewer : Desi Anita

Jurnal ilmiah yang berjudul "**Intelligent recognition of visual speech based on custom CNN and Optimized Quaternion Charlier Moments using PSO**" dipublikasikan di *Ain Shams Engineering Journal* (Volume 17, Tahun 2026, Artikel 103824) oleh Elsevier. Penelitian ini mengusulkan sebuah model baru bernama **QCMs-PSO-CNN** untuk mengenali ucapan visual (lip-reading) secara akurat dari sekuens video menggunakan kombinasi aljabar kuaterner, momen ortogonal, metaheuristik, dan jaringan syaraf tiruan dangkal (shallow CNN).

1. Informasi Bibliografi Jurnal

Parameter	Detail Informasi
Judul Jurnal	Ain Shams Engineering Journal (ASEJ)
Judul Artikel	Intelligent recognition of visual speech based on custom CNN and Optimized Quaternion Charlier Moments using PSO
Penulis	Omar El Ogri, Jaouad EL-Mekkaoui, Mohamed Benslimane, Amal Hjouji, Abdelali Saidi, Musheer Ahmad, Hela Elmannai, Ahmed A. Abd El-Latif
Afiliasi	Sidi Mohamed Ben Abdellah University (Maroko), Chouaib Doukkali University (Maroko), Jamia Millia Islamia (India), Princess Nourah Bint Abdulrahman

Parameter	Detail Informasi
	University (Arab Saudi), Prince Sultan University (Arab Saudi), Jadara University (Yordania)
Garis Waktu Artikel	Diterima: 12 Mei 2025; Direvisi: 17 Agustus 2025; Disetujui: 14 Oktober 2025; Tersedia Online: 25 November 2025 (Kronologi publikasi formal untuk volume tahun 2026).

2. Abstrak dan Inti Ringkasan

Penelitian ini memfokuskan pada Visual Speech Recognition (VSR) atau pembacaan bibir (lip-reading) untuk mengenali kata atau frasa yang diucapkan oleh seseorang dalam video. Model yang diusulkan, **QCMs-PSO-CNN**, menggunakan algoritma Particle Swarm Optimization (PSO) yang ditingkatkan dengan bobot inersia linier dan faktor pembelajaran sine-cosine untuk mengoptimalkan Quaternion Charlier Moments (QCMs). Momen kuaterner yang dioptimalkan ini diintegrasikan sebagai filter pada lapisan pertama dari arsitektur custom shallow CNN. Metode ini terbukti mampu memotong dimensi citra video yang tinggi, menghemat waktu pelatihan jaringan, serta meningkatkan akurasi pengenalan huruf, angka, maupun kata secara signifikan dibanding model deep learning yang lebih kompleks.

3. Masalah Utama dalam Visual Speech Recognition (VSR)

Sistem pembacaan bibir otomatis dihadapkan pada sejumlah tantangan inheren dalam komunikasi manusia, di antaranya:

- **Variasi Fonem dan Visem:** Rentang fonem yang luas (45 hingga 53) memiliki kemiripan visual yang sangat tinggi saat diucapkan (disebut visem).
- **Homofon Visual:** Kata-kata seperti "right" dan "write" memiliki bentuk pergerakan bibir yang identik secara visual meskipun artinya berbeda.
- **Variabilitas Pembicara:** Cara berbicara setiap orang tidaklah sama; terdapat perbedaan bentuk mulut ketika terbuka lebar, tertutup rapat, artikulasi lidah, dan visibilitas gigi.
- **Kompleksitas Data Video:** Dimensi spasial dan temporal video memerlukan daya komputasi tinggi jika diproses langsung menggunakan arsitektur deep learning konvensional yang sangat dalam.

4. Metodologi dan Kontribusi Teknis Utama

4.1. Representasi Citra Berwarna dengan Kuaterner

Citra RGB direpresentasikan menggunakan aljabar kuaterner murni untuk menghindari hilangnya informasi spasial antar-saluran warna (Red, Green, Blue):

$$f(x, y) = f_R(x, y)i + f_G(x, y)j + f_B(x, y)k$$

Di mana i, j, k merupakan unit imajiner kuaterner yang memenuhi hukum non-komutatif Hamilton.

4.2. Quaternion Charlier Moments (QCMs) Teroptimasi

Momen Charlier diskret digunakan sebagai deskriptor fitur global dan lokal dari citra bibir. Polinomial Charlier bergantung pada parameter diskret tertentu. Untuk mendapatkan kualitas ekstraksi fitur terbaik, parameter polinomial ini dioptimalkan menggunakan versi PSO yang telah dikembangkan oleh penulis. Optimasi didasarkan pada minimalisasi nilai Mean Square Error (MSE) dalam rekonstruksi citra.

4.3. Pengembangan Algoritma PSO Baru

Algoritma PSO konvensional dimodifikasi guna mencegah partikel terjebak dalam optimum lokal dan mempercepat konvergensi menggunakan dua mekanisme mendasar:

1. **Bobot Inersia Linier Dinamis (w):** Diturunkan secara linier dari nilai awal yang tinggi (0.9) ke nilai akhir yang rendah (0.4) seiring bertambahnya iterasi guna memperluas eksplorasi global di awal dan eksploitasi lokal di akhir.
2. **Faktor Pembelajaran Sine-Cosine ($c1$ dan $c2$):** Komponen kognitif ($c1$) diturunkan secara monoton dengan fungsi sinus, sedangkan komponen sosial ($c2$) dinaikkan secara monoton dengan fungsi kosinus. Hal ini membatasi partikel agar tidak berkelana berlebihan di akhir proses evolusi.

4.4. Arsitektur Komparatif Jaringan (Custom Shallow CNN)

Alih-alih menyuplai citra spasial mentah langsung ke CNN, model ini menempatkan filter **QCMS-PSO** di lapisan pertama. Filter ini menghasilkan matriks koefisien momen kuaterner berdimensi rendah dari gambar input. Desain ini secara drastis memangkas jumlah parameter jaringan syaraf. Arsitektur CNN selanjutnya terdiri dari:

- 4 Lapisan Konvolusi (Conv Layers) yang dilengkapi dengan Batch Normalization (BN).
- Fungsi aktivasi RELU/ELU dan 3 lapisan Max Pooling untuk reduksi dimensi spasial.
- 2 Fully Connected Layers (400 neuron dan 300 neuron; dimodifikasi menjadi 2720 dan

1200 neuron untuk dataset berskala besar seperti GLips).

- Lapisan Akhir Softmax untuk klasifikasi kelas ucapan.

5. Eksperimen, Dataset, dan Evaluasi

Evaluasi model dilakukan pada tiga dataset visual standar dengan pendekatan spesifik:

- **GRID Dataset:** Berisi 34 pembicara (18 pria, 16 wanita) dengan total 34.000 video berdurasi 3 detik. Pengujian menggunakan protokol *speaker-independent* (SI) di mana 26 pembicara digunakan sebagai data training dan 8 pembicara sebagai data testing.
- **LRW (Lip Reading in the Wild) Dataset:** Terdiri dari 500 kata unik yang diucapkan oleh pembicara di saluran TV BBC. Setiap video memiliki panjang 29 frame (1.2 detik).
- **GLips (German Lipreading) Dataset:** Dataset berskala besar yang mencakup 250.000 video wajah pembicara di Parlemen Hessian, yang dibagi ke dalam 500 kata berbeda.

Pendekatan Preprocessing - CFI (Concatenated Frame Image): Sekuens video direduksi informasinya secara spasio-temporal ke dalam sebuah citra tunggal dengan menggabungkan frame-frame video ke dalam susunan baris dan kolom (citra CFI), seperti format gabungan r kuadrat frame yang memetakan seluruh pergerakan mulut dalam satu gambar.

6. Hasil Eksperimen dan Perbandingan Performa

Model QCMs-PSO-CNN menunjukkan keunggulan mutlak dibandingkan metode-metode canggih lainnya dalam literatur ilmiah. Berikut adalah tabel ringkasan perbandingan akurasi pengenalan ucapan visual:

Dataset	Metode yang Dibandingkan	Akurasi (%)
LRW Dataset	Proposed QCMs-PSO-CNN (SI)	99.95%
	QCMs-CNN tanpa PSO (SI)	91.42%
	HCNN (Hahn CNN)	59.23%
	ResNet LSTM / LSTM-RNN	58.93% / 59.18%
GRID Dataset	Proposed QCMs-PSO-CNN (SI)	99.89%
	QCMs-CNN tanpa PSO (SI)	92.28%
	LipNet (End-to-End Sentence-level)	95.21%
	LSTM + NNs (SI)	76.61%
GLips Dataset	Proposed QCMs-PSO-CNN (SI)	99.97%
	QCMs-CNN tanpa PSO (SI)	94.37%
	alm-GRU + Data Augmentation	85.53%

Dataset	Metode yang Dibandingkan	Akurasi (%)
	(DA)	
	RTMRBM	71.77%

Berdasarkan studi ablasi kedua yang dilakukan pada metrik komprehensif (Akurasi, Presisi, Recall, dan F1-Score), model QCMs-PSO-CNN secara konsisten memperoleh skor keseimbangan di atas **99%** di seluruh parameter pengujian citra bibir, melampaui arsitektur 3DCNN + CFS-DCTCN maupun arsitektur DBNFTLSTM.

7. Kesimpulan dan Prospek Masa Depan

Penelitian ini berhasil membuktikan bahwa penyematan deskriptor matematis ortogonal (Quaternion Charlier Moments) yang dikombinasikan dengan optimasi metaheuristik dinamis (PSO baru) mampu mengungguli model-model deep learning berarsitektur dalam (deep/complex architectures) seperti LipNet atau 3D CNN dalam pemrosesan visual speech recognition. Model ini efisien karena mampu memproses sekuens spasio-temporal lewat citra terkompresi tunggal (CFI) dengan akurasi ekstrem melampaui 99.8% pada tiga dataset global terkemuka.

Untuk pengembangan ke depan, para penulis merencanakan perluasan metode QCMs-PSO-CNN pada sistem berdimensi lebih tinggi, integrasi elemen stokastik untuk menangani gangguan computer vision di lingkungan robotika/augmented reality, serta melakukan investigasi terhadap stabilitas kontrol sinkronisasi jaringan syaraf berbasis memristif inersial maupun Markovian jump neural networks.